

Machine Learning

Concepts et méthodologie


`marie.szafranski@ensiie.fr`

Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique. . .


Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...




Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...




Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...




Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...



Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...




Apprentissage *automatique* vs apprentissage *statistique*?

- Approche **algorithmique** pour l'inférence
- Approche **théorique** des garanties offertes par le modèle

Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...




Apprentissage *automatique* vs apprentissage *statistique* ?

- Approche **algorithmique** pour l'inférence
- Approche **théorique** des garanties offertes par le modèle

Approches **complémentaires** et **indissociables**

Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...




Exemples classiques

Catégorisation de texte

- x_i : suite finie de mots-clés caractérisant un document i $x_i \in \mathcal{X}$
- y_i : catégorie (auteur, sujet, etc.) $y_i \in \mathcal{C}$

Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...



Exemples classiques

Reconnaissance de chiffres manuscrits


- x_i : image i en niveau de gris sur M pixels
- y_i : chiffre

$$x_i \in [0, 1]^M$$

$$y_i \in \{0, \dots, 9\}$$

Parlons « machine learning »

Apprentissage automatique, numérique, artificiel, statistique...



Exemples classiques

Aide au diagnostic médical

- x_i : fréquence cardiaque, respiratoire, etc. du patient i $x_i \in \mathbb{R}^M$
- y_i : diagnostic, prognostic $y_i \in \{\text{malade, sain}\}, y_i \in \mathbb{N}$

Parlons « machine learning »

Différents apprentissages

- Non-supervisé

$$S_u = \{x_u\}_{u=1}^N$$

→ **Inférer** les étiquettes $\{y_u\}_{u=1}^N$ de S_u (classes inconnues)

- Supervisé et semi-supervisé

$$S_\ell = \{(x_\ell, y_\ell)\}_{\ell=1}^N \text{ et } S_u$$

→ **Inférer** les étiquettes y d'exemples x **inédits**

- Par renforcement

$$S_t = \{(e_t, a_t, r_t, e_{t+1})\}_{t=1}^N$$

→ **Inférer** une **politique** $\Pi : a_t(e_t) \rightsquigarrow e_{t+1} : r_t$

→ **Maximiser** la somme des récompenses

Parlons « machine learning »

Différents apprentissages

- Non-supervisé

$$S_u = \{x_u\}_{u=1}^N$$

→ Inférer les étiquettes $\{y_u\}_{u=1}^N$ de S_u (classes inconnues)

- Supervisé et semi-supervisé

$$S_\ell = \{(x_\ell, y_\ell)\}_{\ell=1}^N \text{ et } S_u$$

→ Inférer les étiquettes y d'exemples x inédits

- Par renforcement

$$S_t = \{(e_t, a_t, r_t, e_{t+1})\}_{t=1}^N$$

→ Inférer une politique $\Pi : a_t(e_t) \rightsquigarrow e_{t+1} : r_t$

→ Maximiser la somme des récompenses

Parlons « machine learning »

Différents apprentissages

- Non-supervisé

$$S_u = \{x_u\}_{u=1}^N$$

→ **Inférer** les étiquettes $\{y_u\}_{u=1}^N$ de S_u (classes inconnues)

- Supervisé et semi-supervisé

$$S_\ell = \{(x_\ell, y_\ell)\}_{\ell=1}^N \text{ et } S_u$$

→ **Inférer** les étiquettes y d'exemples x **inédits**

- Par renforcement

$$S_t = \{(e_t, a_t, r_t, e_{t+1})\}_{t=1}^N$$

→ **Inférer** une **politique** $\Pi : a_t(e_t) \rightsquigarrow e_{t+1} : r_t$

→ **Maximiser** la somme des récompenses

Parlons « machine learning »

Apprentissage supervisé

$$S = \{(x_i, y_i)\}_{i=1}^N$$
$$\forall i, (x_i, y_i) \in \mathcal{X} \times \mathcal{Y}$$

Parlons « machine learning »

Apprentissage supervisé

$$S = \{(x_i, y_i)\}_{i=1}^N$$
$$\forall i, (x_i, y_i) \in \mathcal{X} \times \mathcal{Y}$$

Selon \mathcal{Y}

- Régression
- Classification ou discrimination

$y \in \mathbb{R}$ ou $y \in \mathbb{R}^C$, avec $C \in \mathbb{N}$

$y \in \{1, \dots, C\}$, avec $C \in \mathbb{N}$

Classification binaire

$C = 2, y \in \{\pm 1\}$

Parlons « machine learning »

Apprentissage supervisé

$$S = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$$
$$\forall i, (\mathbf{x}_i, y_i) \in \mathcal{X} \times \mathcal{Y}$$

Selon \mathcal{Y}

- Régression
- Classification ou discrimination

Classification binaire


$$y \in \mathbb{R} \text{ ou } y \in \mathbb{R}^C, \text{ avec } C \in \mathbb{N}$$

$$y \in \{1, \dots, C\}, \text{ avec } C \in \mathbb{N}$$

$$C = 2, y \in \{\pm 1\}$$

Parlons « machine learning »


Apprentissage automatique, numérique, artificiel, statistique...



Quelques intuitions

- Espace de recherche \mathcal{H} potentiellement infini
- Capacité de généralisation de h
- Qualité de l'échantillon x


$$h \in \mathcal{H}$$



Quelques intuitions

- Espace de recherche \mathcal{H} potentiellement infini
- Capacité de généralisation de h
- Qualité de l'échantillon x


$$h \in \mathcal{H}$$



Quelques intuitions

- Espace de recherche \mathcal{H} potentiellement infini
- Capacité de généralisation de h
- Qualité de l'échantillon x


$$h \in \mathcal{H}$$



Quelques intuitions

- Espace de recherche \mathcal{H} potentiellement infini
- Capacité de **généralisation** de h
- Qualité de l'échantillon x


$$h \in \mathcal{H}$$



Quelques intuitions

- Espace de recherche \mathcal{H} potentiellement infini
- Capacité de **généralisation** de h
- Qualité de l'échantillon x


$$h \in \mathcal{H}$$



Quelques intuitions

- Espace de recherche \mathcal{H} potentiellement infini
- Capacité de **généralisation** de h
- Qualité de l'échantillon x


$$h \in \mathcal{H}$$



Quelques intuitions

- Espace de recherche \mathcal{H} potentiellement infini
- Capacité de **généralisation** de h
- **Qualité** de l'échantillon x


$$h \in \mathcal{H}$$




Références en ligne (légalement)




En français



En français

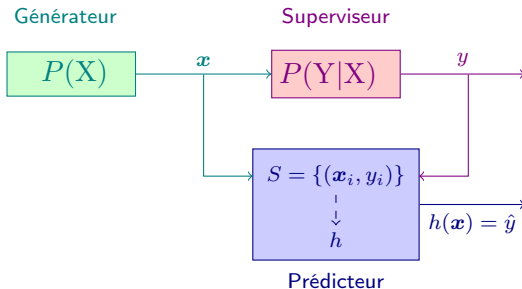


Composante d'un modèle d'apprentissage



- **Générateur** de vecteurs aléatoires X $x \stackrel{\text{iid}}{\sim} P(X)$ (fixe mais inconnue)
- **Superviseur** de variables aléatoires Y $y \stackrel{\text{iid}}{\sim} P(Y|X)$ (fixe mais inconnue)
- **Prédicteur** $h \in \mathcal{H}$ $\mathcal{H} = \{h : \mathcal{X} \rightarrow \mathcal{Y}\}$ (espace des **hypotheses**)

Composante d'un modèle d'apprentissage



$$S \stackrel{\text{iid}}{\sim} P(X, Y) = P(X) \cdot P(Y|X)$$

- Obtenir des valeurs de \hat{y}_i **proches** de y_i , $\forall (x_i, y_i) \in S$
- **Prédire** des valeurs \hat{y} pour des exemples x **inédits**

Remarques

Une solution h déterministe, mais...

- Les données x sont peut-être très bruitées
- L'espace des description \mathcal{X} est peut-être incomplet
- La solution y du problème cible n'est peut-être pas déterministe

Une solution h paramétrique ou non ?

- Pas d'*a priori* sur la forme de $P(X)$
- Pas de contrainte *a priori* sur l'espace de recherche \mathcal{H}

Remarques

Une solution h déterministe, mais...

- Les données x sont peut-être très bruitées
- L'espace des description \mathcal{X} est peut-être incomplet
- La solution y du problème cible n'est peut-être pas déterministe

Une solution h paramétrique ou non ?

- Pas d'*a priori* sur la forme de $P(X)$
- Pas de contrainte *a priori* sur l'espace de recherche \mathcal{H}

Le but du jeu

Choisir la solution h qui « se trompe le moins »

Fonction de perte

Définition

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$\begin{aligned} L : \mathcal{Y} \times \mathcal{Y} &\rightarrow \mathbb{R}^+ \\ (y, h(\mathbf{x})) &\mapsto L(y, h(\mathbf{x})) \end{aligned} \quad \begin{array}{l} 0 \text{ si } y = h(\mathbf{x}) \text{ et } > 0 \text{ sinon} \end{array}$$

Fonction de perte

Définition

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+ \\ (y, h(x)) \mapsto L(y, h(x)) \quad 0 \text{ si } y = h(x) \text{ et } > 0 \text{ sinon}$$

$$|y - h(x)|$$

$$(y - h(x))^2$$

$$\mathbb{I}[y \neq h(x)]$$

???

Fonction de perte

Définition

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+ \\ (y, h(x)) \mapsto L(y, h(x)) \quad 0 \text{ si } y = h(x) \text{ et } > 0 \text{ sinon}$$

$$|y - h(x)|$$

$$(y - h(x))^2$$

$$\mathbb{I}[y \neq h(x)]$$

???

Fonction de perte

Définition

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+ \\ (y, h(x)) \mapsto L(y, h(x)) \quad 0 \text{ si } y = h(x) \text{ et } > 0 \text{ sinon}$$

$$|y - h(x)|$$

$$(y - h(x))^2$$

$$\mathbb{I}[y \neq h(x)]$$

???

Fonction de perte

Définition

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$\begin{aligned} L : \mathcal{Y} \times \mathcal{Y} &\rightarrow \mathbb{R}^+ \\ (y, h(\mathbf{x})) &\mapsto L(y, h(\mathbf{x})) \end{aligned} \quad \begin{array}{l} 0 \text{ si } y = h(\mathbf{x}) \text{ et } > 0 \text{ sinon} \end{array}$$

$$|y - h(\mathbf{x})|$$

$$(y - h(\mathbf{x}))^2$$


$$\mathbb{I}[y \neq h(\mathbf{x})]$$

???

Fonction de perte

Définir une perte $L(y, h(\mathbf{x}))$ cohérente avec la tâche

Classification binaire : $y = \{\pm 1\}$



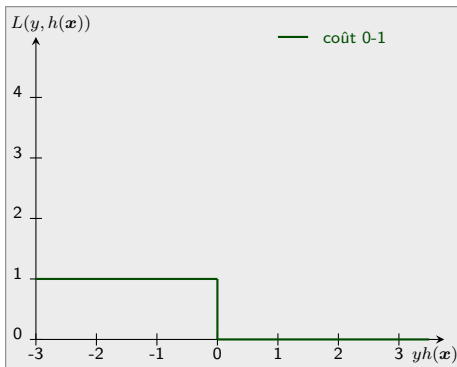
Soit $d(\mathbf{x}) = \text{sign}(h(\mathbf{x}))$

- $L(y, h(\mathbf{x})) = I_{\text{sign}}[y \neq h(\mathbf{x})]$
- $L(y, h(\mathbf{x})) = [1 - yh(\mathbf{x})]_+$

Fonction de perte

Définir une perte $L(y, h(\mathbf{x}))$ cohérente avec la tâche

Classification binaire : $y = \{\pm 1\}$




Soit $d(\mathbf{x}) = \text{sign}(h(\mathbf{x}))$

- $L(y, h(\mathbf{x})) = I_{\text{sign}}[y \neq h(\mathbf{x})]$
- $L(y, h(\mathbf{x})) = [1 - yh(\mathbf{x})]_+$

Fonction de perte

Définir une perte $L(y, h(\mathbf{x}))$ cohérente avec la tâche

Classification binaire : $y = \{\pm 1\}$




Soit $d(\mathbf{x}) = \text{sign}(h(\mathbf{x}))$

- $L(y, h(\mathbf{x})) = I_{\text{sign}}[y \neq h(\mathbf{x})]$
- $L(y, h(\mathbf{x})) = [1 - yh(\mathbf{x})]_+$


Fonction de perte

Définir une perte $L(y, h(\mathbf{x}))$ cohérente avec la tâche

Classification binaire



Régression



Crédits : <http://www.cs.cornell.edu/courses/cs4780/2015fa/web/lecturenotes/lecturenote10.html>

Fonction de perte et risque réel

Fonction de perte

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+ \\ (y, h(\mathbf{x})) \mapsto L(y, h(\mathbf{x})) \quad 0 \text{ si } y = h(\mathbf{x}) \text{ et } > 0 \text{ sinon}$$

Risque réel

$$R(h) = E[L(Y, h(X))] = P(h(X) \neq Y)$$

$$\bullet \quad R(h) = \int \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x} dy$$

Régression

$$\bullet \quad R(h) = \int_{\mathcal{X}} \sum_{y \in \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x}$$

Classification

Fonction de perte et risque réel

Fonction de perte

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+ \\ (y, h(\mathbf{x})) \mapsto L(y, h(\mathbf{x})) \quad 0 \text{ si } y = h(\mathbf{x}) \text{ et } > 0 \text{ sinon}$$

Risque réel

$$R(h) = E[L(Y, h(X))] = P(h(X) \neq Y)$$

$$\bullet \quad R(h) = \int \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x} dy$$

Régression

$$\bullet \quad R(h) = \int_{\mathcal{X}} \sum_{y \in \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x}$$

Classification

Fonction de perte et risque réel

Fonction de perte

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+ \\ (y, h(\mathbf{x})) \mapsto L(y, h(\mathbf{x})) \quad 0 \text{ si } y = h(\mathbf{x}) \text{ et } > 0 \text{ sinon}$$

Risque réel

$$R(h) = E[L(Y, h(X))] = P(h(X) \neq Y)$$

$$\bullet \quad R(h) = \int \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x} dy$$

Régression

$$\bullet \quad R(h) = \int_{\mathcal{X}} \sum_{y \in \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x}$$

Classification

Fonction de perte et risque réel

Fonction de perte

Coût, critère

Quantifier l'erreur comise par h pour évaluer y

$$L : \mathcal{Y} \times \mathcal{Y} \rightarrow \mathbb{R}^+ \\ (y, h(x)) \mapsto L(y, h(x)) \quad 0 \text{ si } y = h(x) \text{ et } > 0 \text{ sinon}$$

Risque réel

$$h^* = \operatorname{argmin}_h R(h)$$

$$R(h) = E[L(Y, h(X))] = P(h(X) \neq Y)$$

$$\bullet R(h) = \int \int_{\mathcal{X} \times \mathcal{Y}} L(y, h(x)) P(x, y) dx dy$$

Régression

$$\bullet R(h) = \int_{\mathcal{X}} \sum_{y \in \mathcal{Y}} L(y, h(x)) P(x, y) dx$$

Classification

Risque empirique

Risque réel

$$R(h) = \int_{\mathcal{X}} \sum_{y \in \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x}$$

Risque empirique

Risque réel

$P(X, Y)$ et en particulier $P(Y|X)$ inconnus

$$R(h) = \int_{\mathcal{X}} \sum_{y \in \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x}$$

Risque empirique

Risque réel

$P(X, Y)$ et en particulier $P(Y|X)$ inconnus

$$R(h) = \int_{\mathcal{X}} \sum_{y \in \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x}$$

Hypothèse de loi uniforme

Hypothèse : $P(\mathbf{x}_i, y_i) = 1/N$

Risque empirique

Risque réel

$P(X, Y)$ et en particulier $P(Y|X)$ inconnus

$$R(h) = \int_{\mathcal{X}} \sum_{y \in \mathcal{Y}} L(y, h(\mathbf{x})) P(\mathbf{x}, y) d\mathbf{x}$$

Hypothèse de loi uniforme

Hypothèse : $P(\mathbf{x}_i, y_i) = 1/N$

$$\text{Risque : } R_{emp}(h) = \frac{1}{N} \sum_{i=1}^N L(y_i, h(\mathbf{x}_i))$$

$$\text{Solution : } h_S^* = \operatorname{argmin}_{h \in \mathcal{H}} R_{emp}(h)$$

Décomposition du risque empirique

Soit $h_S^* = \operatorname{argmin}_{h \in \mathcal{H}} R_{emp}(h)$

$$R(h_S^*) = R(h^-) + \underbrace{[R(h^*) - R(h^-)]}_{\text{Biais}} + \underbrace{[R(h_S^*) - R(h^*)]}_{\text{Variance}}$$

- Difficulté intrinsèque du problème \rightsquigarrow incompressible (quantité de bruit)
- Adéquation de l'espace de recherche \mathcal{H}
- Erreur liée au principe de Minimisation du Risque Empirique (MRE)

Décomposition du risque empirique

Soit $h_S^* = \operatorname{argmin}_{h \in \mathcal{H}} R_{emp}(h)$

$$R(h_S^*) = R(h^-) + \underbrace{[R(h^*) - R(h^-)]}_{\text{Biais}} + \underbrace{[R(h_S^*) - R(h^*)]}_{\text{Variance}}$$

- Difficulté intrinsèque du problème \rightsquigarrow incompressible (quantité de bruit)
- Adéquation de l'espace de recherche \mathcal{H}
- Erreur liée au principe de Minimisation du Risque Empirique (MRE)

Décomposition du risque empirique

Soit $h_S^* = \operatorname{argmin}_{h \in \mathcal{H}} R_{emp}(h)$

$$R(h_S^*) = R(h^-) + \underbrace{[R(h^*) - R(h^-)]}_{\text{Biais}} + \underbrace{[R(h_S^*) - R(h^*)]}_{\text{Variance}}$$

- Difficulté intrinsèque du problème \rightsquigarrow incompressible (quantité de bruit)
- Adéquation de l'espace de recherche \mathcal{H}
- Erreur liée au principe de Minimisation du Risque Empirique (MRE)

Décomposition du risque empirique

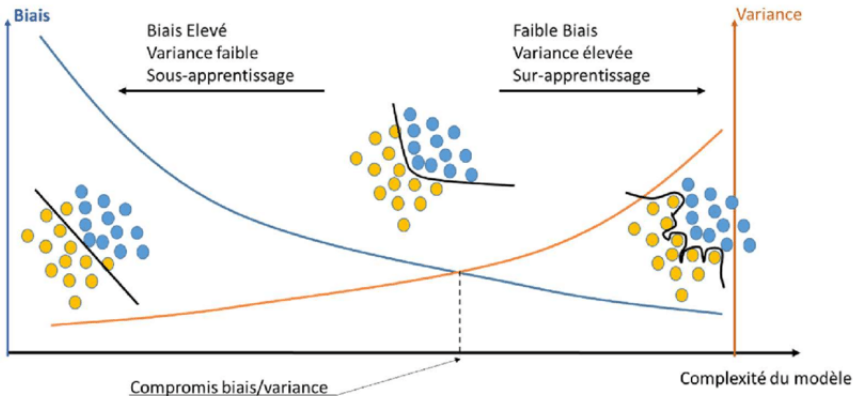
Soit $h_S^* = \operatorname{argmin}_{h \in \mathcal{H}} R_{emp}(h)$

$$R(h_S^*) = R(h^-) + \underbrace{[R(h^*) - R(h^-)]}_{\text{Biais}} + \underbrace{[R(h_S^*) - R(h^*)]}_{\text{Variance}}$$

- Difficulté intrinsèque du problème \rightsquigarrow incompressible (quantité de bruit)
- Adéquation de l'espace de recherche \mathcal{H}
- Erreur liée au principe de Minimisation du Risque Empirique (MRE)

Décomposition du risque empirique

Dilemme Biais vs Variance



Crédits : Pascal Scalar – introduction au DM

Quelques questions

L'objectif est-il réalisable ?

\rightsquigarrow consistance du processus d'apprentissage

Quelques questions

L'objectif est-il réalisable ?

\rightsquigarrow consistance du processus d'apprentissage

MRE : processus **consistant** dans \mathcal{H}

$$h_S^* \xrightarrow[N \rightarrow \infty]{} h^*$$

Quelques questions

L'objectif est-il réalisable ?

\rightsquigarrow consistance du processus d'apprentissage

MRE : processus **consistant** dans \mathcal{H}

$$h_S^* \xrightarrow[N \rightarrow \infty]{} h^*$$

Si oui, comment ?

- Construction d'algorithmes
- Contrôle de la vitesse de convergence

Quelques questions

L'objectif est-il réalisable ?

\rightsquigarrow consistance du processus d'apprentissage

MRE : processus **consistant** dans \mathcal{H}

$$h_S^* \xrightarrow[N \rightarrow \infty]{} h^*$$

Si oui, comment ?

- Construction d'algorithmes
- Contrôle de la vitesse de convergence

Vers la minimisation du **risque structurel**

Régression polynomiale

$$D = 1$$

Données

$$S = \{(t_i, x_i)\}_{i=1}^N$$

Processus réel

$$t = h(x)$$

Modèle

$$\hat{t}_{i'} = h_m(x_{i'}) = \sum_{m=0}^M \alpha_m x_{i'}^m$$

Régression polynomiale

$$D = 1$$

Données


Processus réel

Modèle


$$S = \{(t_i, x_i)\}_{i=1}^N$$

$$t = h(x)$$


$$\hat{t}_{i'} = h_m(x_{i'}) = \sum_{m=0}^M \alpha_m x_{i'}^m$$



Sous-apprentissage



Apprentissage « correct »



Sur-apprentissage

Exemple tiré du cours de Vincent Charvillat

Les K plus proches voisins


 $(K\text{-nn})$

Données

Modèle

$$S = \{(x_i, y_i)\}_{i=1}^N, \text{ } y_i = 1 \text{ ou } y_i = -1$$

$$h_K \text{ avec } K = \{3, 5, \dots\}$$



Exemple tiré du cours de Wikipedia

En résumé et au delà

Apprentissage supervisé

- Construire un modèle
- À partir d'un ensemble d'apprentissage
- Erreur empirique
Estimation imparfaite de l'erreur de généralisation

$$\hat{y} = h_p(\mathbf{x})$$

$$S_\ell = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n_\ell}$$

→ optimiste

En résumé et au delà

Apprentissage supervisé

- Construire un modèle
- À partir d'un ensemble d'apprentissage
- Erreur empirique
Estimation imparfaite de l'erreur de généralisation

$$\hat{y} = h_p(\mathbf{x})$$

$$S_\ell = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n_\ell}$$

→ optimiste

Méthodologie

- Comment évaluer les performances d'un modèle ?
- Comment choisir un bon modèle ?

En résumé et au delà

Apprentissage supervisé

- Construire un modèle
- À partir d'un ensemble d'apprentissage
- Erreur empirique
Estimation imparfaite de l'erreur de généralisation

$$\hat{y} = h_p(\mathbf{x})$$

$$S_\ell = \{(\mathbf{x}_i, y_i)\}_{i=1}^{n_\ell}$$

→ optimiste

Méthodologie

- Comment évaluer les performances d'un modèle ?
- Comment choisir un bon modèle ?

↪ vignette WikiStat